

Аналитический отчёт

1. Введение

Целью данной работы является построение моделей машинного обучения, позволяющих предсказывать ключевые показатели биологической активности химических соединений: **IC50** (полумаксимальная ингибирующая концентрация), **CC50** (цитотоксическая концентрация) и **SI** (индекс селективности). Также решаются задачи бинарной классификации: превышение IC50, CC50 и SI медианных значений выборки, а также превышение порога $SI > 8$ (клинически значимый уровень). Данные предоставлены в виде 1000 соединений с 214 числовыми признаками (молекулярные дескрипторы), без пропусков. Основные целевые переменные имеют сильно скошенное распределение, что потребовало логарифмирования и удаления выбросов.

2. Разведочный анализ данных (EDA)

- **Пропуски:** отсутствуют во всех столбцах.
- **Распределения целевых переменных:**
Все три величины (IC50, CC50, SI) имеют длинный правый хвост. После логарифмирования ($\log_{10}$) распределения приближаются к нормальным.
Графики распределений сохранены в target_distributions.png.
- **Удаление выбросов:** методом IQR по $\log_{10}$ IC50 из выборки исключено около 5% соединений, что позволило снизить влияние экстремальных значений.
- **Отбор признаков:**
 - Удалены признаки с дисперсией < 0.01 .
 - Для регрессии применялся SelectKBest ($f_{\text{regression}}$, 100 лучших признаков).
 - Топ-10 признаков, наиболее коррелирующих с $\log_{10}$ IC50: NumSaturatedHeterocycles, fr_NH2, VSA_EState4, SlogP_VSA5, NumAliphaticHeterocycles, NumAliphaticCarbocycles, SMR_VSA5, PEOE_VSA7, VSA_EState8, VSA_EState7.
 - Все корреляции являются слабыми (0,18–0,28), что говорит о сложности задачи и необходимости нелинейных моделей.

- **Итог после очистки:** около 950 соединений и ~150 признаков (в зависимости от целевой переменной).

3. Методология

3.1. Предобработка

- Логарифмирование IC50, CC50 и SI ($\log_{10}$).
- Удаление константных/почти константных признаков.
- Удаление строк с пропусками (единичные случаи).
- Масштабирование признаков StandardScaler.
- Для регрессии: отбор 100 лучших признаков с помощью SelectKBest ($f_{\text{regression}}$).
- Для классификации: использовались все оставшиеся признаки (после удаления константных).

3.2. Используемые модели

- **Регрессия:** RandomForestRegressor (RF), GradientBoostingRegressor (GBR), XGBRegressor (XGB).
- **Классификация:** LogisticRegression (LR), RandomForestClassifier (RF), XGBClassifier (XGB).

3.3. Подбор гиперпараметров

Для каждой модели применялся GridSearchCV с 5-кратной перекрёстной проверкой:

- RF: $n_{\text{estimators}} \in \{100, 200\}$, $\text{max_depth} \in \{\text{None}, 10\}$.
- GBR: $n_{\text{estimators}} \in \{100, 200\}$, $\text{learning_rate} \in \{0.05, 0.1\}$.
- XGB: $n_{\text{estimators}} \in \{100, 200\}$, $\text{max_depth} \in \{3, 6\}$, $\text{learning_rate} \in \{0.05, 0.1\}$.
- LR: $C \in \{0.1, 1, 10\}$.

Метрики:

- Регрессия: R^2 , MAE, RMSE.
- Классификация: AUC, Accuracy, F1.

4. Результаты

4.1. Регрессия

4.1.1. Предсказание IC50 (целевая: $\log_{IC50}$)

Модель	R ²	MAE	RMSE
RF	0.323	196.59	432.60
GBR	0.415	196.53	402.01
XGB	0.422	194.88	399.53

Лучшая модель – XGBoost.

4.1.2. Предсказание CC50 (целевая: $\log_{CC50}$)

Модель	R ²	MAE	RMSE
RF	0.276	335.52	583.85
GBR	0.252	350.33	593.58
XGB	0.258	346.97	591.28

Лучшая модель – RandomForestRegressor.

4.1.3. Предсказание SI (целевая: $\log_{SI}$)

Модель	R ²	MAE	RMSE
RF	0.003	182.77	1418.88
GBR	-0.004	183.85	1423.87
XGB	-0.003	183.97	1423.39

Все модели показали крайне низкое качество. Линейной зависимости между признаками и SI обнаружено не было. Для улучшения результата требуется более глубокая инженерия признаков.

4.2. Классификация

4.2.1. IC50 > медианы

Модель	AUC	Асс	F1
LR	0.758	0.715	0.725
RF	0.792	0.735	0.739
XGB	0.791	0.710	0.718

Лучшая модель – RandomForestClassifier.

4.2.2. CC50 > медианы

Модель	AUC	Асс	F1
LR	0.812	0.730	0.750
RF	0.862	0.765	0.777
XGB	0.845	0.775	0.785

Лучший AUC у случайного леса, но по Accuracy и F1 лидирует XGBoost.

4.2.3. SI > медианы

Модель	AUC	Асс	F1
LR	0.665	0.620	0.616
RF	0.693	0.645	0.628
XGB	0.654	0.630	0.622

Скромные результаты, что коррелирует с низким качеством регрессии SI.

4.2.4. SI > 8

Модель	AUC	Асс	F1
LR	0.688	0.645	0.564
RF	0.734	0.700	0.545
XGB	0.713	0.650	0.545

Здесь также заметен дисбаланс классов; F1 невысок. Случайный лес лучше по AUC и Accuracy.

5. Общее сравнение и выбор лучших моделей

- **Регрессия IC50:** XGBoost ($R^2=0.422$). Модель объясняет менее половины дисперсии, но лучше остальных.
- **Регрессия CC50:** RandomForest ($R^2=0.276$). Качество низкое, но это лучшее, что удалось достичь без дополнительной настройки.
- **Регрессия SI:** Практически не поддаётся линейному моделированию. Требуется нелинейный подход (глубокие сети или графовые нейросети).
- **Классификация IC50>медианы:** RandomForest (AUC=0.792, F1=0.739) – хороший результат, применим для скрининга.

- **Классификация CC50>медианы:** Случайный лес (AUC=0.862) и XGBoost (F1=0.785) демонстрируют лучшие показатели. Допустимо использование любого из них.
- **Классификация SI>медианы и SI>8:** RF показывает лучшие метрики, но F1 низкий, что говорит о необходимости дополнительных данных или более сложных архитектур.

6. Выводы и рекомендации

1. Наиболее прогнозируемой оказалась переменная IC50, что объясняется биологической природой дескрипторов – многие из них ориентированы на активность.
2. CC50 и особенно SI значительно сложнее моделируются: линейные и ансамблевые методы улавливают лишь слабые нелинейные зависимости.
3. Для классификационных задач, особенно с медианным порогом, достигнуты приемлемые значения AUC (0.79–0.86), что позволяет применять модели для отсева наименее перспективных соединений на ранних этапах.
4. Для улучшения качества предсказания SI необходимо:
 - Использовать более сложные алгоритмы (нейронные сети, графовые модели).
 - Провести более глубокий инжиниринг признаков (например, добавить фингерпринты соединений).
 - Собрать больший объём данных.
5. В текущей конфигурации для практического использования можно рекомендовать:
 - **Регрессия IC50:** XGBoost.
 - **Классификация CC50>медианы:** RandomForest.
 - Для остальных задач либо доработать признаки, либо перейти к глубокому обучению.

Приложение: код проекта доступен в репозитории GitHub (ссылка). Все скрипты запускаются независимо и формируют метрики, использованные в отчёте.